

差分隐私稀疏向量技术与Transformer门控注意力机制的协同集成研究报告

1. 执行摘要

在当今人工智能领域，大型语言模型 (Large Language Models, LLMs) 的参数规模已扩展至万亿级别，其在自然语言处理、代码生成及多模态推理等任务中展现出了卓越的性能。然而，随着模型能力的提升，其对训练数据的依赖性也愈发增强，这在处理包含敏感个人信息的私有数据（如医疗记录、金融交易及私人通信）时引发了严峻的隐私顾虑。差分隐私 (Differential Privacy, DP) 作为目前隐私保护的黄金标准，提供了在数据分析和模型训练中量化隐私泄露的数学框架。尽管如此，将差分隐私的标准算法——特别是差分隐私随机梯度下降 (DP-SGD)——直接应用于Transformer架构时，面临着显著的“维度诅咒”和架构不兼容性挑战。

本报告深入探讨了将差分隐私中的基础算法原语——稀疏向量技术 (Sparse Vector Technique, SVT)——与Transformer架构中新兴的门控注意力 (Gated Attention) 机制相结合的可行性与理论前景。分析表明，这种结合并非简单的叠加，而是通过利用门控注意力机制引入的“内在稀疏性”与SVT的“选择性隐私预算分配”特性，构建出一种新型的“稀疏差分隐私Transformer”架构。该架构旨在解决传统DP-Transformer训练中存在的两大核心难题：一是由于参数维度过高导致的噪声注入量过大，严重损害模型效用；二是“注意力分散” (Attention Distraction) 现象，即隐私噪声导致模型关注无关词元 (Token)。

本研究综合了关于SVT算法及其高斯/指数噪声变体的基础理论¹，Transformer隐私训练中的最新进展（如Phantom Clipping和Re-Attention机制）⁴，以及门控注意力在消除“注意力汇” (Attention Sinks) 和“大规模激活” (Massive Activations) 方面的实证发现⁴。报告详细阐述了三种核心集成策略：(1) 基于SVT的私有梯度稀疏化，用于在DP-SGD中动态筛选高信息量的参数更新；(2) 通过SVT实现的动态词元剪枝，作为一种私有的“硬门控”机制来减少计算量和隐私消耗；(3) 私有注意力头选择，利用SVT构建差分隐私混合专家 (MoE) 系统。

结论指出，SVT与门控注意力的结合不仅在理论上成立，而且在工程实践中具有巨大的潜力。门控注意力通过非线性变换和输入依赖的稀疏性净化了信号，而SVT则提供了一种加密机制来安全地提取这些稀疏信号，从而在不牺牲隐私保证的前提下显著提升模型的训练效率和最终性能。

2. 大型语言模型中的隐私与效率困境

2.1 差分隐私在深度学习中的应用瓶颈

差分隐私的核心承诺是确保单一数据样本的加入或移除不会显著改变算法的输出分布。在深度学习背景下，这通常通过Abadi等人提出的DP-SGD算法来实现⁵。该过程要求对每个样本的梯度进行裁剪 (Clipping) 以限制灵敏度，随后在聚合梯度上添加高斯噪声。

$$\|\tilde{g}\| = \frac{1}{B} \sum_{i=1}^B \|\text{Clip}(\nabla \theta_i, C)\| + \mathcal{N}(0, \sigma^2)$$

$C^2 l) \cdot d$

然而，Transformer模型的参数量(d)巨大，且标准DP-SGD添加的噪声向量的范数与 $\sqrt{d}$ 成正比。这意味着随着模型规模的扩大，信噪比急剧下降，导致模型难以收敛或性能大幅退化⁷。此外，Ding等人在“Delving into Differentially Private Transformer”一文中指出了Transformer特有的“硬度”：

1. 梯度裁剪的效率问题：标准Transformer采用嵌入共享(Embedding Sharing)机制，导致前向和后向传播的拓扑结构非平坦化。现有的高效梯度裁剪技术(如Ghost Clipping)难以直接应用，迫使研究者在放弃嵌入共享(导致参数增加和泛化能力下降)或承受巨大的计算开销之间做出选择⁴。
2. 注意力分散现象：在长尾数据分布下，DP噪声和梯度裁剪会扭曲注意力分数的计算，导致模型错误地将注意力分配给低频或无关的词元。这种“注意力分散”严重阻碍了模型捕捉长距离依赖的能力⁴。

2.2 门控注意力机制的演进与特性

为了解决Transformer的训练稳定性和推理效率问题，门控注意力(Gated Attention)应运而生。与标准缩放点积注意力(SDPA)不同，门控注意力引入了一个数据依赖的门控单元来调制注意力输出。其通用形式可以表示为：

$$Y' = \text{SDPA}(Q, K, V) \odot \sigma(X W_\theta)$$

其中 σ 通常为Sigmoid激活函数。基于对15B参数MoE模型和1.7B稠密模型的广泛实验，研究者发现门控注意力具有以下关键特性⁴：

- 引入非线性：标准Attention中的值投影(W_V)和输出投影(W_O)本质上是连续的线性变换。门控机制在其中引入了非线性，增加了模型的表达能力，从而提升了低秩映射的有效性⁴。
- 显著的稀疏性(**Pronounced Sparsity**)：最关键的发现是，门控分数表现出强烈的稀疏性。这意味着对于给定的输入，大部分维度的输出被门控机制抑制，只有少部分关键信息被传递。这种输入依赖的稀疏性是SVT介入的理想切入点⁴。
- 消除大规模激活与注意力汇：标准LLM通常表现出“大规模激活”(Massive Activations)和“注意力汇”(Attention Sinks)现象，即初始词元(如<s>)虽然语义信息量低，却积累了极高的注意力权重。门控注意力通过稀疏调制有效地消除了这些异常值，使得注意力分布更加合理，模型训练更加稳定⁴。

2.3 稀疏性作为隐私保护的桥梁

差分隐私与门控注意力的结合点在于稀疏性。在差分隐私领域，稀疏性意味着只需要对少量的非零元素添加噪声，或者只需要对超过阈值的元素支付隐私预算。SVT正是为此设计的算法工具¹。既然门控注意力天然产生稀疏的激活和梯度，那么利用SVT来识别这些稀疏信号，就可以避免对整个稠密参数空间添加噪声，从而从根本上改善信噪比。

3. 稀疏向量技术(SVT): 算法原理与进阶机制

在探讨集成方案之前, 必须深入理解SVT的运作机制及其在深度学习环境下的变体。

3.1 SVT的核心逻辑与隐私优势

稀疏向量技术(SVT), 有时也被称为AboveThreshold算法, 专门用于处理一系列查询, 其中预期只有极少数查询的答案会超过某个阈值。其核心优势在于: 对于低于阈值的查询(负结果), **SVT** 几乎不消耗(或消耗极少)隐私预算¹。

SVT的典型流程如下:

1. 阈值扰动: 输入阈值 T , 添加拉普拉斯噪声生成噪声阈值 $\hat{T} = T + \text{Lap}(\frac{2}{\epsilon_1})$ 。
2. 查询处理: 对于到达的每一个查询 q_i (例如梯度的范数), 计算其真实值 $f(D)$ 。
3. 结果扰动: 添加噪声 $\nu_i = \text{Lap}(\frac{4}{\epsilon_2})$ 。
4. 比较与输出: 如果 $f(D) + \nu_i \geq \hat{T}$, 输出 top (超过阈值), 并消耗隐私预算; 否则输出 perp (未超过), 不消耗或仅消耗微量预算。
5. 终止条件: 当输出 top 的次数达到预设上限 c 时停止。

这种机制使得隐私消耗仅与“显著”事件的数量 c 相关, 而与总查询流的长度无关⁹。这对于深度学习至关重要, 因为在一个庞大的神经网络中, 可能有数百万个参数(总查询流长), 但对于特定样本, 可能只有极少数参数的梯度是显著的(稀疏正结果)。

3.2 算法的正确性与变体

历史上, SVT的变体曾出现过多种证明错误, 导致隐私泄露¹。例如, 如果在输出 top 时同时发布具体的噪声数值, 而不是仅发布布尔值, 就会破坏隐私保证, 因为攻击者可以利用数值反推阈值噪声。因此, 在Transformer中集成SVT时, 必须严格遵守“仅释放索引或布尔状态”的原则, 或者在释放数值时支付额外的预算¹。

近年来的研究引入了更先进的SVT变体:

- **高斯SVT(Gaussian SVT)**: 利用高斯噪声代替拉普拉斯噪声, 并结合Renyi差分隐私(RDP)或零集中差分隐私(zCDP)进行分析。由于高斯分布的尾部衰减更快, 且在高维组合下表现更好, 高斯SVT通常能提供比传统SVT更高的效用²。
- **指数噪声SVT**: Liu等人证明, 使用指数机制形式的噪声进行阈值比较, 在某些设定下是最优的, 可以进一步提升查询精度³。
- **多维SVT**: 针对图算法等场景, 扩展了SVT以处理多维向量查询, 这为处理Transformer中的多头注意力提供了理论基础¹⁴。

4. 门控注意力与SVT的深度集成策略

本节详细阐述如何将SVT嵌入到门控注意力Transformer的训练和推理循环中, 构建“稀疏差分隐

私Transformer”。

4.1 策略一：基于SVT的私有梯度稀疏化

在训练阶段，最大的挑战是梯度的高维性。Google的DP-AdaFEST研究表明，通过自适应过滤选择重要梯度可以大幅减少噪声影响⁸。结合门控注意力，我们可以设计一种架构感知的梯度选择机制。

机制设计：

在门控注意力层中，门控函数 $\sigma(XW_{\theta})$ 决定了特征的重要性。

1. 梯度计算：计算回传梯度的范数 $\|\nabla W\|$ 。由于门控机制的存在，梯度本身呈现稀疏分布。
2. 私有选择：使用SVT作为选择器。
 - 查询：参数块或单个参数的梯度范数。
 - 阈值：基于历史梯度统计量的自适应阈值。
3. 稀疏更新：SVT输出一个稀疏掩码 $M \in \{0, 1\}^d$ 。仅对 $M_i=1$ 的参数进行更新。
4. 噪声注入：在添加噪声时，噪声的尺度仅需与被选中的参数数量（即稀疏度）成正比，而非总参数量。

优势分析：

门控注意力机制通过抑制无关信息的正向传播，天然地导致了反向传播梯度的稀疏化。与在普通网络上强行应用SVT相比，在门控网络上应用SVT能获得更高的召回率(Recall)和精度(Precision)，因为“真实”的显著梯度与噪声梯度的分离度更高⁴。这种方法直接缓解了DP-SGD在大型模型上的信噪比问题。

4.2 策略二：基于SVT的动态词元剪枝(Dynamic Token Pruning)

在推理和微调阶段，Transformer的计算成本随序列长度二次方增长。动态词元剪枝旨在去除无信息的词元¹⁵。

机制设计：

将门控注意力的“软门控”(Soft Gating, $\sigma(\cdot)$)替换为基于SVT的“私有硬门控”(Private Hard Gating, $\{0, 1\}$)。

1. 计算门控分数：利用小型网络计算每个词元的重要性分数 S_t 。
2. SVT判决：将 S_t 输入SVT，与阈值 T 比较。
3. 剪枝：
 - 若 SVT 输出 $\perp$ ：该词元在本层及后续层中被丢弃(Masked out)。
 - 若 SVT 输出 $\top$ ：保留词元参与注意力计算。

隐私与效用的双重收益：

- 隐私收益：通过剪枝，模型输出对被剪枝词元的依赖被切断，降低了灵敏度。此外，SVT本身保证了“剪枝决策”这一过程的差分隐私性¹⁶。
- 效用收益：减少了“注意力分散”。如Ding等人所述，DP噪声容易导致模型关注无关词元⁴。通过SVT强制剪枝低分词元，可以物理上阻断这种错误的注意力流，提升模型在长尾分布下的

鲁棒性。

关键考量 - 注意力汇 (Attention Sinks) 的保护：

“Attention Sink”理论指出，LLM必须保留初始的几个词元作为“汇”来维持数值稳定性，即使它们没有语义意义⁴。如果SVT盲目地剪枝这些分数可能不高的初始词元，模型会崩溃。

因此，必须实施**“汇感知 (Sink-Aware)”的SVT策略**：强制保留前\$K\$个词元 (不经过SVT筛选)，仅对剩余上下文应用SVT剪枝。这与流式LLM (Streaming LLM) 的策略一致，确保了在引入隐私机制时不会破坏模型的机械稳定性⁴。

4.3 策略三：私有注意力头选择 (Private Head Selection)

Transformer的多头注意力机制通常包含大量冗余。SVT可以用来动态选择活跃的注意力头，类似于混合专家 (MoE) 模型中的门控网络，但具有隐私保证。

机制设计：

- 1. 计算每个注意力头的相关性得分。
- 2. 应用SVT选择Top-\$k\$个显著的头。
- 3. 仅计算和聚合这些被选中的头的输出。

这构建了一个**差分隐私混合专家注意力 (Differentially Private Mixture-of-Attention-Heads)** 系统。在联邦学习场景下 (Fed-SVT)，这种方法尤为有效，可以显著减少通信量，并防止服务器通过梯度反推客户端的私有数据结构¹⁷。

下表总结了三种集成策略的对比：

集成策略	作用阶段	应用对象	核心优势	潜在风险
私有梯度稀疏化	训练	梯度向量	降低噪声方差，突破DP维度诅咒 ⁸	若阈值不当，可能丢失关键更新
动态词元剪枝	推理/微调	输入词元	减少计算量，缓解注意力分散 ⁴	需特殊保护“注意力汇”以免模型崩溃 ⁴
私有头选择	训练/推理	注意力头	类似MoE的稀疏性，通信高效 ¹⁷	可能导致某些头从未被训练 (死神经元)

5. 解决架构挑战与技术细节

5.1 阈值选择的困境与自适应方案

SVT的性能极度依赖于阈值 τ 的选择。阈值过高导致召回率低，阈值过低导致隐私预算耗尽。在非凸优化(如训练Transformer)中，梯度的范数会随时间剧烈变化。

因此，必须采用**自适应阈值(Adaptive Thresholding)**策略。参考DP-IGHT算法 19 和CAPRI系统 20，可以将阈值 τ 设为动态变量，基于上一轮的梯度统计量或利用一部分隐私预算进行在线估计。例如，使用分位数估计(Quantile Estimation)来确定每一层的梯度范数中位数，并以此设定下一轮的SVT阈值。

5.2 Phantom Clipping 与 SVT 的协同

前文提到，标准Transformer难以进行高效的逐样本梯度裁剪。Ding等人提出的Phantom Clipping技术通过重构计算图，无需实例化逐样本梯度即可计算其范数⁴。

这为SVT的应用铺平了道路：

1. 利用Phantom Clipping高效计算每个样本的梯度范数 $\|\mathbf{g}_i\|$ 。
2. 应用SVT筛选哪些样本的梯度是“有效”的(即范数在合理范围内且方向显著)。
3. 仅聚合通过SVT筛选的样本梯度。

这种结合实际上实现了一种**私有的样本选择(Private Sample Selection)**机制，能够在噪声注入前剔除异常值(Outliers)或无效数据，进一步净化训练信号⁴。

5.3 解决“注意力分散”的闭环

Re-Attention机制旨在修正被噪声扭曲的注意力分布⁴。将SVT引入其中，可以形成一个更强的闭环：

- Re-Attention利用贝叶斯推断校准注意力分数的分布参数(均值和方差)。
- SVT利用校准后的分布作为输入，执行硬阈值切断。
- 这种组合确保了SVT是在“去噪”后的信号上进行操作，减少了因DP噪声导致的误判(False Positives)，从而更精准地保留关键的语义依赖⁴。

6. 隐私预算管理与高级组合

6.1 预算分配的经济学

SVT的一个关键特性是，对于长序列的负结果(Below Threshold)，其隐私消耗极低⁹。在Transformer中，由于门控注意力的稀疏性，绝大多数词元或梯度的相关性都极低(即处于负结果状态)。

这意味着，我们可以对一个极长的序列(如文档中的数千个词元)运行SVT，而只支付与“活跃词元数”成正比的隐私预算，而不是与“序列总长度”成正比。这对于处理长文本(Long Context)的隐私保护至关重要，突破了传统DP机制在长序列上预算爆炸的限制⁹。

6.2 Renyi差分隐私(RDP)的应用

为了进一步收紧隐私界限，应当在RDP框架下分析SVT与高斯机制的组合。RDP允许更精细的组合分析，特别是在SVT这种包含随机停止和适应性查询的复杂机制中。使用高斯SVT(Gaussian SVT)并在RDP下核算，通常能比纯 ϵ -DP节省大量的预算，使得在有限的 ϵ (如 $\epsilon < 10$)下训练大型模型成为可能²。

7. 案例研究与实证依据

7.1 联邦学习中的Fed-SVT

在联邦学习场景下，¹⁷ 和 ¹⁷ 提出的Fed-SVT算法展示了SVT在专家选择中的威力。在每一轮通信中，客户端利用SVT判断当前的模型(专家)是否仍然适用，仅在误差超过阈值时请求更新。实验表明，这种方法在保持隐私的同时，实现了后悔值(Regret)的指数级下降，证明了SVT在动态选择任务中的高效性。

7.2 视觉Transformer中的Dual-Priv Pruning

在多模态领域，Dual-Priv Pruning¹⁶ 利用注意力分数作为显著性指标，对视觉词元进行剪枝。这实际上是SVT逻辑的一种变体：基于阈值筛选Token。该研究证明，减少Token数量直接降低了输入维度，从而减少了所需的DP噪声量，提升了下游任务的准确率。这为在纯文本Transformer中应用SVT剪枝提供了强有力的实证支持。

7.3 Google的DP-AdaFEST

Google提出的DP-AdaFEST算法⁸ 专门针对稀疏梯度更新。它利用一种自适应过滤机制(本质上是SVT的变体)来选择特征桶(Feature Buckets)。实验显示，该方法能将梯度大小减少 10^5 倍，同时保持模型精度。这直接验证了“稀疏化+差分隐私”在大规模嵌入模型训练中的可行性和巨大潜力。

8. 结论与展望

8.1 结论

将稀疏向量技术(SVT)与Transformer中的门控注意力机制相结合，不仅是可行的，而且是解决大型语言模型隐私训练难题的关键路径。

- 架构契合度：门控注意力提供的“内在稀疏性”与SVT的“稀疏感知隐私计费”形成了完美的互补。门控创造了稀疏信号，SVT低成本地捕获了这些信号。
- 问题解决：这种结合直接针对了“维度诅咒”(通过梯度稀疏化)、“注意力分散”(通过SVT硬门控)和“效率瓶颈”(通过动态剪枝)这三大核心挑战。
- 稳定性保障：通过引入“汇感知”(Sink-Aware)设计，SVT可以在不破坏Transformer内部机制(如Attention Sinks)的前提下实施剪枝。

8.2 未来建议

1. 标准化组件：开发封装好的“DP-Gated-Attention”层，内部集成SVT逻辑和Phantom Clipping，使其成为PyTorch等框架的标准组件。
2. 硬件加速：稀疏计算在GPU上通常效率不高。未来的研究应关注如何利用SVT产生的稀疏掩码来优化底层计算内核(Kernels)，实现真正的加速。
3. 自适应阈值研究：深入研究基于层级统计量的无参数阈值设定方法，减少超参数调整的隐私成本。

综上所述, 稀疏差分隐私**Transformer**代表了隐私保护AI的未来方向, 它不再试图对整个庞大的网络进行全量的噪声保护, 而是智能地、私有地选择关键信息进行学习, 从而打破了隐私与效用之间的零和博弈。

数据来源索引:

1 (SVT基础与原理); 4 (DP Transformer挑战与Phantom Clipping); 4 (门控注意力与稀疏性); 4 (Attention Sinks与稳定性); 8 (梯度稀疏化); 15 (动态剪枝); 17 (MoE与选择)。

引用的著作

1. Understanding the Sparse Vector Technique for Differential Privacy - VLDB Endowment, 访问时间为 一月 11, 2026, <http://www.vldb.org/pvldb/vol10/p637-lyu.pdf>
2. Improving Sparse Vector Technique with Renyi Differential Privacy - NeurIPS, 访问时间为 一月 11, 2026, <https://proceedings.neurips.cc/paper/2020/hash/e9bf14a419d77534105016f5ec122d62-Abstract.html>
3. Unleash the Power of Ellipsis: Accuracy-enhanced Sparse Vector Technique with Exponential Noise - VLDB Endowment, 访问时间为 一月 11, 2026, <https://www.vldb.org/pvldb/vol18/p187-liu.pdf>
4. Efficient Streaming Language Models with Attention Sinks.pdf
5. DP-SGD: Private Stochastic Gradient Descent - Emergent Mind, 访问时间为 一月 11, 2026, <https://www.emergentmind.com/topics/differentially-private-stochastic-gradient-descent-dp-sgd>
6. Improving Differentially Private SGD via Randomly Sparsified Gradients - OpenReview, 访问时间为 一月 11, 2026, <https://openreview.net/pdf?id=sY35BAIf4>
7. Differentially Private Optimization with Sparse Gradients - OpenReview, 访问时间为 一月 11, 2026, <https://openreview.net/pdf?id=4Ktifp48WD>
8. Sparsity-preserving differentially private training - Google Research, 访问时间为 一月 11, 2026, <https://research.google/blog/sparsity-preserving-differentially-private-training/>
9. The Sparse Vector Technique — Programming Differential Privacy, 访问时间为 一月 11, 2026, <https://programming-dp.com/chapter10.html>
10. Understanding the Sparse Vector Technique for Differential Privacy - ResearchGate, 访问时间为 一月 11, 2026, https://www.researchgate.net/publication/301841865_Understanding_the_Sparse_Vector_Technique_for_Differential_Privacy
11. (PDF) Differentially Private Selection using Smooth Sensitivity - ResearchGate, 访问时间为 一月 11, 2026, https://www.researchgate.net/publication/384928410_Differentially_Private_Selection_using_Smooth_Sensitivity
12. Improving Sparse Vector Technique with Renyi Differential Privacy - NeurIPS, 访问

时间为 一月 11, 2026,

<https://proceedings.neurips.cc/paper/2020/file/e9bf14a419d77534105016f5ec122d62-Paper.pdf>

13. accuracy-enhanced sparse vector technique with exponential noise - arXiv, 访问时间为 一月 11, 2026, <https://arxiv.org/pdf/2407.20068>
14. Near-Optimal Differentially Private Graph Algorithms via the Multidimensional AboveThreshold Mechanism - arXiv, 访问时间为 一月 11, 2026, <https://arxiv.org/html/2508.02182v1>
15. Dynamic Token Pruning in Plain Vision Transformers for Semantic Segmentation - CVF Open Access, 访问时间为 一月 11, 2026, https://openaccess.thecvf.com/content/ICCV2023/papers/Tang_Dynamic_Token_Pruning_in_Plain_Vision_Transformers_for_Semantic_Segmentation_ICCV_2023_paper.pdf
16. Dual-Priv Pruning : Efficient Differential Private Fine-Tuning in Multimodal Large Language Models | OpenReview, 访问时间为 一月 11, 2026, <https://openreview.net/forum?id=MKXIYeLMQU>
17. Federated Online Prediction from Experts with Differential Privacy: Separations and Regret Speed-ups - NIPS papers, 访问时间为 一月 11, 2026, https://proceedings.neurips.cc/paper_files/paper/2024/file/e3490ed7541c826d9156c322c910e41b-Paper-Conference.pdf
18. Mixture-of-Experts based Model Market - VLDB Endowment, 访问时间为 一月 11, 2026, https://www.vldb.org/2025/Workshops/VLDB-Workshops-2025/DEC/DEC25_2.pdf
19. Differentially Private Iterative Gradient Hard Thresholding for Sparse Learning - IJCAI, 访问时间为 一月 11, 2026, <https://www.ijcai.org/proceedings/2019/0519.pdf>
20. (PDF) Capacity Planning Under Local Differential Privacy With Optimized Budget Selection - ResearchGate, 访问时间为 一月 11, 2026, https://www.researchgate.net/publication/385674684_Capacity_Planning_Under_Local_Differential_Privacy_With_Optimized_Budget_Selection
21. DPFORMER: LEARNING DIFFERENTIALLY PRIVATE TRANSFORMER ON LONG-TAILED DATA - OpenReview, 访问时间为 一月 11, 2026, <https://openreview.net/pdf?id=WvVyG8qBCt>
22. Differentially Private Clustering in Data Streams - arXiv, 访问时间为 一月 11, 2026, <https://arxiv.org/pdf/2307.07449>
23. [1603.01699] Understanding the Sparse Vector Technique for Differential Privacy - arXiv, 访问时间为 一月 11, 2026, <https://arxiv.org/abs/1603.01699>
24. JunyiZhu-AI/RandomSparsification: Improving Differentially Private SGD via Randomly Sparsified Gradients [Accepted by TMLR] - GitHub, 访问时间为 一月 11, 2026, <https://github.com/JunyiZhu-AI/RandomSparsification>